

# Clasificador de Setas.

Modelado Machine Learning categórico o de reconocimiento de imagen.

**Hugo Martín-Santos**  
Alumno Bootcamp Data Science  
The Bridge


*Lasarte-Oria/Madrid*  
*01/XII/2023*

# Plan de ataque

- Obtención de Data.
- Análisis de Data.
- Diseño de modelado.
- Entrenamiento de modelos.
- Desarrollo APP.




Illustrations by Pixeltrue on  
[icons8](#)



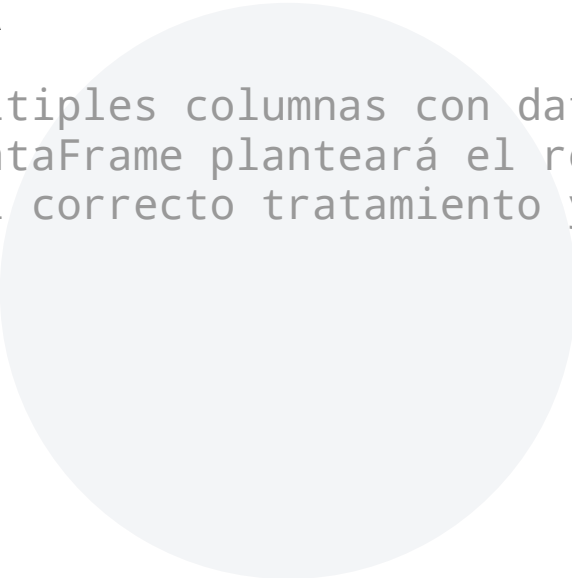


# **Problema de Clasificación multicategórico**

## **Retos a tener en cuenta**



La presencia de múltiples columnas con data categórica en el DataFrame planteará el reto de cómo afrontar el correcto tratamiento y pre-procesamiento.



01

## **Análisis**

*Valoración de parámetros.  
Descartes y primeros  
tratamientos.*

03

## **OneHotEncoding**

*Paso final. Pérdida de  
legibilidad, pero adecuación  
necesaria al problema de ML.*

02

## **Expansión de categorías**

*La multi-categoría se aborda  
creando filas por cada  
combinación existente.*

04

## **Modelado**

*Trabajo de  
hiperparametrización y  
planteamiento de modelos  
múltiples.*



## Dataframe Original

173 x 15

○	☆ □	□ ○	⬠	○ ▽
⬠	△ ○ □	⬠ △ ○	□	▽
□	□ ⬠	▽ □	▽	□
☆	□ ☆	☆ □	□	☆
△	☆ ▽	▽ □	☆	○

multicategoría y multiclase

## Dataframe explotado

6525 x 15

○	□	□	⬠	▽
○	□	□	⬠	○
○	□	□	□	▽
○	□	□	□	○
○	□	□	▽	▽
○	□	□	▽	○
○	□	□	☆	▽
○	□	□	☆	○

Una sola combinación de categorías por línea

Tratamiento DataFrame

OneHotEncoding (Sacar Dummies)

## DataFrame de trabajo


6525 x 98

	□	□	□	□	□	☆	☆	☆	☆	▽	▽	▽	▽	▽	○	○	○	○	○	○	○
○																					
○																					
○																					
○																					
○																					
○																					

Columnas categóricas binarias, adecuadas para el aprendizaje ML

	name	cap-diameter	cap-shape	cap-surface	cap-color	gill-color	stem-height	stem-width	stem-surface	stem-color	veil-color	has-ring	ring-type	habitat	season
0	Fly Agaric	[10, 20]	[x, f]	[g, h]	[e, o]	[w]	[15, 20]	[15, 20]	[y]	[w]	[w]	[t]	[g, p]	[d]	[u, a, w]
1	Panther Cap	[5, 10]	[p, x]	[g]	[n]	[w]	[6, 10]	[10, 20]	[y]	[w]	[w]	[t]	[p]	[d]	[u, a]
2	False Panther Cap	[10, 15]	[x, f]	NaN	[g, n]	[w]	[10, 12]	[10, 20]	NaN	[w]	[w]	[t]	[e, g]	[d]	[u, a]
3	The Blusher	[5, 15]	[x, f]	NaN	[n]	[w]	[7, 15]	[10, 25]	NaN	[w]	[w]	[t]	[g]	[d]	[u, a]
4	Death Cap	[5, 12]	[x, f]	[h]	[r]	[w]	[10, 12]	[10, 20]	NaN	[w]	[w]	[t]	[g, p]	[d]	[u, a]
5	False Death Cap	[4, 9]	[x]	NaN	[w, y]	[w]	[5, 7]	[10, 15]	NaN	[w, y]	[y, w]	[t]	[g]	[d]	[u, a]
6	Destroying Angel	[5, 10]	[b]	[t]	[w]	[w]	[10, 15]	[10, 15]	[y]	[w]	[w]	[t]	[l, e]	[d]	[u, a]
7	Tawny Grisette	[4, 8]	[c, x]	[h, t]	[n]	[w]	[10, 15]	[10, 15]	[s]	[w, n]	[w]	[f]	[f]	[d]	[u, a]
8	Parasol Mushroom	[10, 25]	[p, f]	[y]	[w, n]	[w]	[15, 35]	[15, 25]	NaN	[n]	NaN	[t]	[m]	[m, d]	[u, a]
9	Shaggy Parasol	[12, 18]	[x]	[e, y]	[n]	[w]	[8, 12]	[15, 20]	NaN	[w]	NaN	[t]	NaN	[g, d]	[u, a]

[illegible]




# Reconocimiento de imágenes

# Red Neuronal Convolutacional

## Retos a tener en cuenta

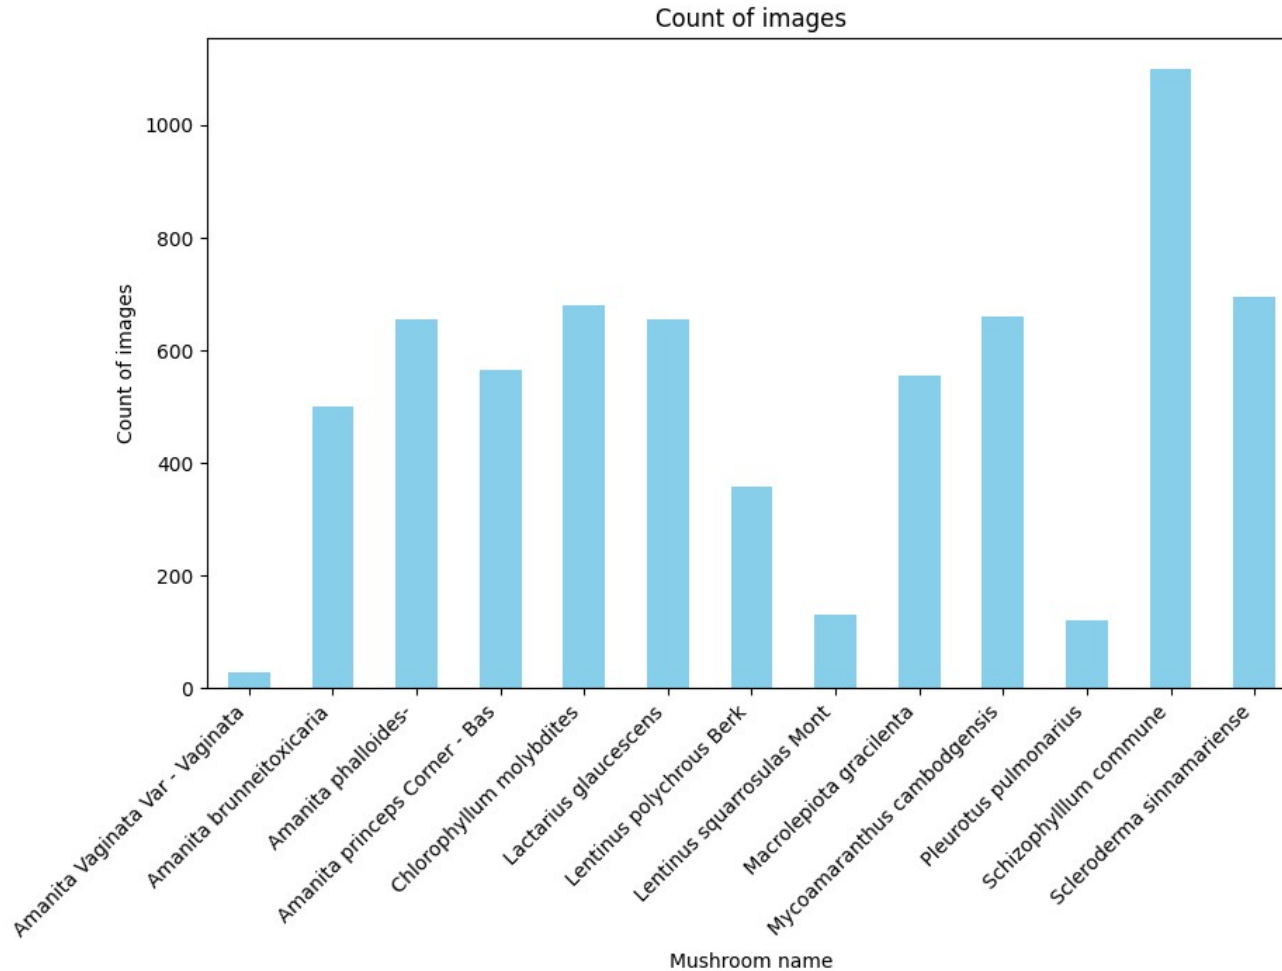
El preprocesamiento de imágenes y el diseño de una estructura del modelo apta para su procesamiento será vital para conseguir el éxito.

# Procesamiento de imágenes





## Cantidad de imágenes por target.



Este  
desequilibrio en  
la representación  
de ciertas  
categorías habrá  
que tratarlo para  
evitar el  
overfitting/under  
sampling.

# Diseño de Estructura neuronal modelo tensorflow Keras

## Capas Red Neuronal

```
layers = [  
    keras.layers.Conv2D(128, (3,3), activation='relu', input_shape=(48,48,3)),  
    keras.layers.MaxPooling2D(pool_size=(2,2)),  
    keras.layers.Dropout(0.1),  
  
    keras.layers.Conv2D(64, (3,3), activation='relu'),  
    keras.layers.MaxPooling2D(pool_size=(2,2)),  
    keras.layers.Dropout(0.1),  
  
    keras.layers.Conv2D(64, (3,3), activation='relu'),  
    keras.layers.MaxPooling2D(pool_size=(2,2)),  
    keras.layers.Dropout(0.1),  
  
    keras.layers.Flatten(),  
    keras.layers.Dense(128, activation='relu'),  
    keras.layers.Dense(32, activation='relu'),  
    keras.layers.Dropout(0.1),  
    keras.layers.Dense(13, activation='sigmoid')  
]  
  
cnn_model = keras.Sequential(layers)  
  
cnn_model.compile(optimizer = 'adam',  
                  loss = 'categorical_crossentropy',  
                  metrics = ['accuracy'])
```

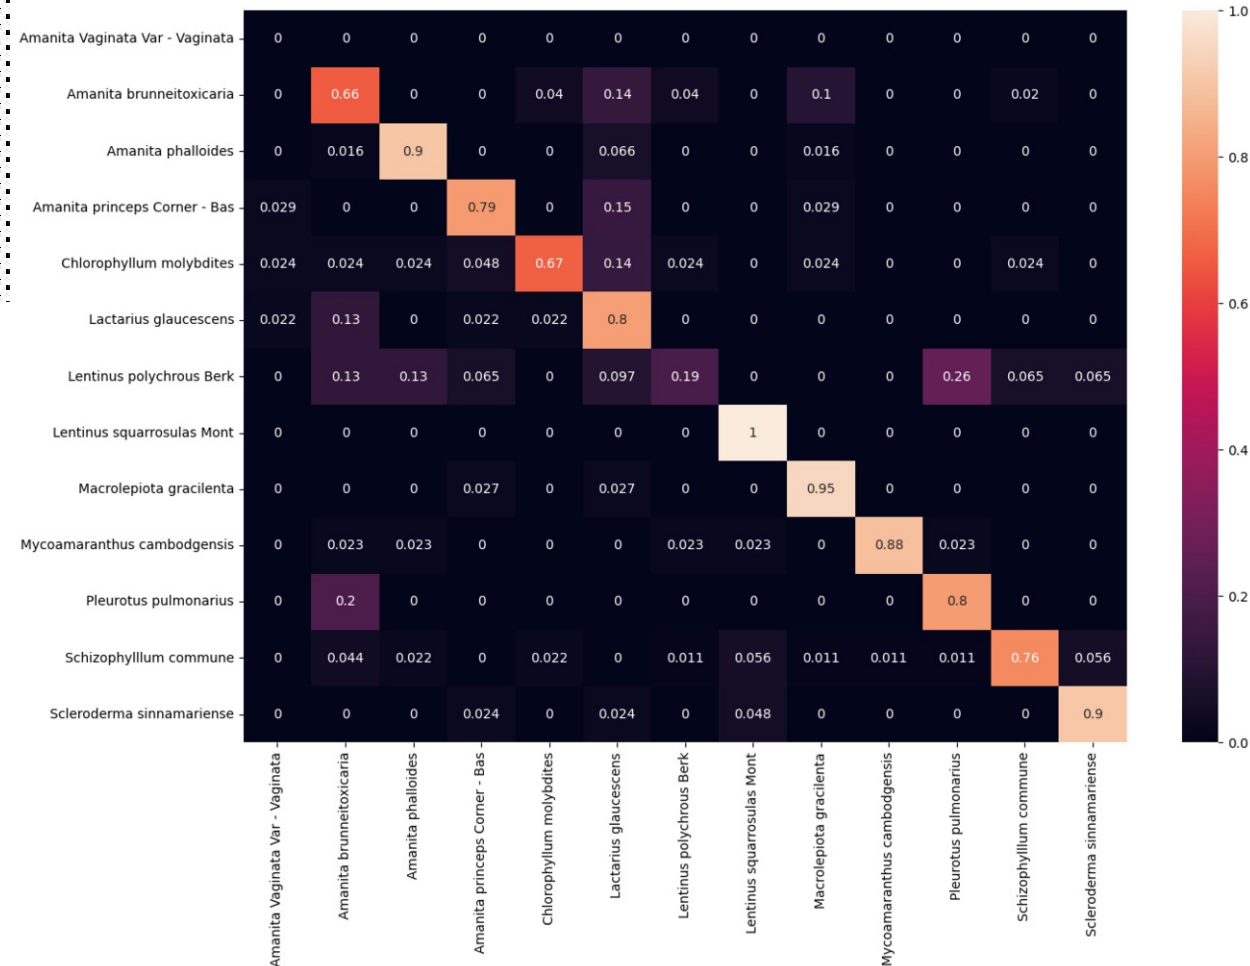
## Sumario estructura

Model: "sequential\_3"

Layer (type)	Output Shape	Param #
=====		
conv2d_7 (Conv2D)	(None, 46, 46, 128)	3584
max_pooling2d_7 (MaxPooling2D)	(None, 23, 23, 128)	0
dropout (Dropout)	(None, 23, 23, 128)	0
conv2d_8 (Conv2D)	(None, 21, 21, 64)	73792
max_pooling2d_8 (MaxPooling2D)	(None, 10, 10, 64)	0
dropout_1 (Dropout)	(None, 10, 10, 64)	0
conv2d_9 (Conv2D)	(None, 8, 8, 32)	18464
max_pooling2d_9 (MaxPooling2D)	(None, 4, 4, 32)	0
dropout_2 (Dropout)	(None, 4, 4, 32)	0
...		
Total params: 163181 (637.43 KB)		
Trainable params: 163181 (637.43 KB)		
Non-trainable params: 0 (0.00 Byte)		

## Matriz de confusión

### Test nunca antes visto por el modelo



Ciertas categorías no terminan de ser bien asimiladas por el modelo. Quedaría profundizar en el porqué de los casos particularmente malos.

En general el modelo se comporta según lo esperado.